

UNIVERSITÉ De Nouakchott
FACULTÉ De Sciences Et Techniques

MASTER : AI_MLDS

Année Universitaire : 2025 – 2026

PIPELINE HYBRIDE DEEP LEARNING – MACHINE LEARNING POUR LA CLASSIFICATION D'IMAGES CIFAR-10

Projet Intégrateur AML & ADL

Réalisé par :

Mohamed abdellahi Mohamed El Hafedh El Bah C34602

Mohamed Mahmoud Ahmed Said C34666

Mariam Mahfoudh Abeidallah C18948

Encadrant :

Dr. Rivaa Sadegh

Juin 2026

Résumé

L'objectif de ce projet est de concevoir et d'évaluer un pipeline hybride combinant Deep Learning et Machine Learning pour la classification d'images. L'approche proposée utilise un modèle ResNet18 pré-entraîné comme extracteur de caractéristiques profondes, suivi de techniques de réduction de dimension et de plusieurs algorithmes de Machine Learning.

Les caractéristiques extraites sont ensuite exploitées par différents modèles de classification, notamment Random Forest, XGBoost, LightGBM et Stacking. Les expériences sont réalisées sur le dataset CIFAR-10 composé de 60 000 images réparties en dix catégories.

Les résultats montrent que les méthodes de boosting obtiennent les meilleures performances. Le meilleur modèle de l'étude est LightGBM associé à PCA avec une accuracy de 85.92 %. Cette étude met en évidence l'intérêt des approches hybrides combinant la puissance de représentation des réseaux de neurones profonds et l'efficacité des algorithmes modernes de Machine Learning.

Mots-clés : Deep Learning, Machine Learning, ResNet18, PCA, UMAP, XGBoost, LightGBM, Stacking, CIFAR-10.

Abstract

The objective of this project is to design and evaluate a hybrid Deep Learning and Machine Learning pipeline for image classification. The proposed approach relies on a pretrained ResNet18 model used as a deep feature extractor, followed by dimensionality reduction techniques and several Machine Learning algorithms.

The extracted features are then processed by different classifiers including Random Forest, XGBoost, LightGBM and Stacking. Experiments are conducted on the CIFAR-10 dataset containing 60,000 images distributed across ten classes.

Results demonstrate that boosting-based approaches outperform traditional Random Forest models. The best performance is achieved by LightGBM combined with PCA, reaching an accuracy of 85.92%. This study highlights the effectiveness of hybrid approaches that combine the representational power of Deep Learning with the efficiency of modern Machine Learning algorithms.

Keywords: Deep Learning, Machine Learning, ResNet18, PCA, UMAP, XGBoost, LightGBM, Stacking, CIFAR-10.

Table des matières

Résumé.....	2
Abstract.....	2
Table des matières.....	3
1. Introduction	4
2. État de l'art.....	4
2.1 Deep Learning	4
2.2 Réseaux de neurones convolutifs	4
2.3 Transfer Learning	5
2.4 ResNet18.....	5
2.5 Réduction de dimension	5
3. Méthodologie.....	6
3.1 Présentation du Dataset	6
3.2 Prétraitement des Images.....	6
3.3 Extraction des Deep Features	6
3.4 Réduction de Dimension par PCA	7
3.5 Réduction de Dimension par UMAP	8
3.6 Modèles de Machine Learning.....	8
4. Résultats Expérimentaux	10
4.1 Résultats de PCA	10
4.2 Résultats de UMAP	10
4.3 Comparaison des Performances	12
4.4 Analyse des Temps d'Exécution.....	12
4.5 Comparaison Globale.....	13
4.6 Interprétabilité des Modèles avec SHAP	14
5. Discussion.....	16
6. Limites de l'Étude.....	16
7. Conclusion.....	17
Bibliographie	18

1. Introduction

La classification d'images constitue l'une des tâches fondamentales de la vision par ordinateur. Grâce aux progrès réalisés dans le domaine du Deep Learning, les performances des systèmes de classification ont considérablement augmenté au cours de la dernière décennie.

Les réseaux de neurones convolutifs (CNN) ont joué un rôle déterminant dans cette évolution. Leur capacité à apprendre automatiquement des représentations hiérarchiques à partir des données brutes leur permet d'atteindre des performances remarquables dans de nombreux domaines tels que la reconnaissance d'objets, la détection d'anomalies ou encore l'analyse médicale.

Cependant, l'entraînement complet d'un réseau profond nécessite généralement des ressources matérielles importantes ainsi qu'un volume conséquent de données annotées. Par ailleurs, certaines applications nécessitent des modèles plus rapides à entraîner ou plus simples à interpréter.

Dans ce contexte, les approches hybrides combinant Deep Learning et Machine Learning représentent une alternative particulièrement intéressante. L'idée consiste à exploiter un réseau de neurones pré-entraîné comme extracteur de caractéristiques puis à utiliser ces représentations comme entrée d'algorithmes de Machine Learning classiques.

Cette stratégie permet de bénéficier simultanément :

- de la qualité des représentations apprises par les réseaux profonds ;
- de la simplicité d'utilisation des algorithmes de Machine Learning ;
- d'une réduction du coût d'entraînement ;
- d'une meilleure flexibilité pour tester différents classifieurs.

L'objectif principal de ce projet est de développer un pipeline hybride capable de classifier les images du dataset CIFAR-10 à partir de caractéristiques profondes extraites par ResNet18. Plusieurs algorithmes de Machine Learning sont ensuite évalués afin d'identifier la solution la plus performante.

2. État de l'art

2.1 Deep Learning

Le Deep Learning est une branche de l'intelligence artificielle basée sur l'utilisation de réseaux de neurones comportant plusieurs couches de traitement. Ces architectures permettent l'apprentissage automatique de représentations complexes directement à partir des données.

Le succès du Deep Learning dans le domaine de la vision par ordinateur est principalement dû à sa capacité à apprendre automatiquement des caractéristiques pertinentes sans intervention humaine.

2.2 Réseaux de neurones convolutifs

Les réseaux de neurones convolutifs constituent aujourd'hui la référence pour les tâches de classification d'images.

Ils reposent sur plusieurs composants :

- couches de convolution ;
- fonctions d'activation ;
- couches de pooling ;
- couches entièrement connectées.

Les premières couches apprennent généralement des caractéristiques simples telles que les contours et les textures tandis que les couches profondes apprennent des concepts plus abstraits.

2.3 Transfer Learning

Le Transfer Learning consiste à réutiliser un modèle préalablement entraîné sur une grande base de données afin de résoudre une nouvelle tâche.

Cette approche présente plusieurs avantages :

- réduction du temps d'apprentissage ;
- diminution du besoin en données annotées ;
- amélioration de la généralisation.

Dans ce projet, un modèle ResNet18 pré-entraîné sur ImageNet est utilisé comme extracteur de caractéristiques.

2.4 ResNet18

ResNet18 appartient à la famille des réseaux résiduels introduits par He et al. en 2015.

L'innovation principale de ResNet repose sur l'utilisation de connexions résiduelles permettant de faciliter l'apprentissage de réseaux profonds et de limiter le problème de disparition du gradient.

Grâce à sa robustesse et à sa simplicité, ResNet18 est devenu l'un des modèles les plus utilisés dans les approches de Transfer Learning.

2.5 Réduction de dimension

Les techniques de réduction de dimension permettent de diminuer le nombre de variables tout en conservant l'information essentielle.

Deux méthodes sont étudiées dans ce travail :

- Principal Component Analysis (PCA)
- Uniform Manifold Approximation and Projection (UMAP)

PCA est une méthode linéaire basée sur la maximisation de la variance tandis que UMAP est une méthode non linéaire cherchant à préserver les relations de voisinage entre les observations.

3. Méthodologie

3.1 Présentation du Dataset

Les expérimentations ont été réalisées sur le dataset CIFAR-10, l'un des jeux de données les plus utilisés dans le domaine de la vision par ordinateur. Il a été développé par le Canadian Institute for Advanced Research et constitue une référence pour l'évaluation des algorithmes de classification d'images.

Le dataset contient :

- 60 000 images couleur ;
- taille de 32×32 pixels ;
- 10 classes distinctes ;
- 50 000 images pour l'apprentissage ;
- 10 000 images pour les tests.

Les dix catégories sont :

- Airplane
- Automobile
- Bird
- Cat
- Deer
- Dog
- Frog
- Horse
- Ship
- Truck

L'utilisation de CIFAR-10 permet de comparer facilement les performances obtenues avec celles rapportées dans la littérature scientifique.

3.2 Prétraitement des Images

Le modèle ResNet18 pré-entraîné sur ImageNet nécessite des images de taille 224×224 pixels.

Les transformations suivantes ont été appliquées :

1. Redimensionnement des images vers 224×224 .
2. Conversion vers le format Tensor PyTorch.
3. Normalisation des pixels.

Ces opérations assurent la compatibilité entre le dataset CIFAR-10 et le réseau de neurones utilisé.

3.3 Extraction des Deep Features

L'étape principale du pipeline consiste à extraire automatiquement des caractéristiques visuelles pertinentes à partir des images.

Pour cela, le modèle ResNet18 pré-entraîné sur ImageNet a été utilisé.

La dernière couche de classification a été supprimée afin de conserver uniquement la partie extraction de caractéristiques du réseau.

Pour chaque image, le réseau produit un vecteur de :

512 caractéristiques profondes

Ces caractéristiques représentent une description compacte et riche du contenu visuel de l'image.

Le pipeline devient alors :

Images CIFAR-10 → ResNet18 → 512 Deep Features

3.4 Réduction de Dimension par PCA

Les 512 caractéristiques extraites par ResNet18 contiennent certaines redondances.

Afin de réduire la complexité des données, l'Analyse en Composantes Principales (PCA) a été appliquée.

Le nombre de composantes a été fixé à :

100 composantes principales

La courbe de variance expliquée montre qu'environ :

81 % de la variance totale

est conservée après réduction.

Cette étape présente plusieurs avantages :

- diminution du temps de calcul ;
- réduction du bruit ;
- simplification de l'espace de représentation.

La transformation réalisée est :

512 dimensions → 100 dimensions

3.5 Réduction de Dimension par UMAP

Une seconde méthode de réduction de dimension a été étudiée :

UMAP (Uniform Manifold Approximation and Projection)

Contrairement à PCA, UMAP est une méthode non linéaire.

Dans cette étude :

512 dimensions → 50 dimensions

La projection UMAP en deux dimensions a également été utilisée afin de visualiser la structure des données.

Les résultats montrent la formation de plusieurs groupes correspondant aux différentes classes du dataset.

Cette visualisation confirme la qualité des caractéristiques extraites par ResNet18.

3.6 Modèles de Machine Learning

Après extraction des deep features, plusieurs algorithmes de Machine Learning ont été évalués.

Random Forest

Random Forest est une méthode d'apprentissage par ensemble reposant sur plusieurs arbres de décision.

Chaque arbre effectue sa propre prédiction. La décision finale est obtenue par vote majoritaire.

Les paramètres utilisés sont :

- 200 arbres ;
- random_state = 42.

XGBoost

XGBoost est une méthode de boosting basée sur des arbres de décision.

Chaque nouvel arbre corrige les erreurs produites par les arbres précédents.

Paramètres principaux :

- 200 estimateurs ;
- profondeur maximale = 8 ;
- learning rate = 0.1.

LightGBM

LightGBM est une implémentation optimisée des méthodes de boosting.

Ses principaux avantages sont :

- rapidité ;

- faible consommation mémoire ;
- excellentes performances.

Stacking

Le Stacking consiste à combiner plusieurs modèles afin d'obtenir une prédiction finale plus robuste.

Les prédictions des modèles de base sont utilisées comme entrée d'un méta-modèle chargé de produire la décision finale.

Cette approche vise à exploiter les forces complémentaires de plusieurs algorithmes.

4. Résultats Expérimentaux

4.1 Résultats de PCA

La courbe de variance expliquée cumulée montre que les 100 premières composantes principales conservent environ 81 % de l'information contenue dans les 512 caractéristiques originales.

Cette observation justifie le choix de PCA comme technique de réduction de dimension.




Figure 1 — PCA : variance expliquée cumulée en fonction du nombre de composantes.

4.2 Résultats de UMAP

La projection UMAP permet de visualiser les caractéristiques extraites par ResNet18 dans un espace bidimensionnel.

Les observations appartenant à la même classe tendent à se regrouper.

Cette séparation confirme que les deep features contiennent une information discriminante importante.




Figure 2 — Projection UMAP 2D des deep features extraites par ResNet18, colorées par classe.

4.3 Comparaison des Performances

Les performances des différents modèles sont présentées dans le tableau suivant.

Modèle	Accuracy (%)
Random Forest	82.62
Random Forest + PCA	82.13
Random Forest + UMAP	81.55
XGBoost + PCA	85.38
LightGBM + PCA	85.92
Stacking + PCA	85.51

Le meilleur résultat est obtenu par LightGBM + PCA.

4.4 Analyse des Temps d'Exécution

Les temps mesurés ou estimés sont résumés dans le tableau suivant.

Modèle	Temps (secondes)
Random Forest	427.64
Random Forest + PCA	320.9
Random Forest + UMAP	350.5
XGBoost + PCA	209.90
LightGBM + PCA	150.6
Stacking + PCA	500.1

Les résultats montrent que PCA réduit significativement le coût computationnel.

LightGBM apparaît comme le meilleur compromis entre rapidité et précision.

4.5 Comparaison Globale

L'analyse des résultats permet de classer les modèles selon leur précision :

1. LightGBM + PCA (85.92 %)
2. Stacking + PCA (85.51 %)
3. XGBoost + PCA (85.38 %)
4. Random Forest (82.62 %)
5. Random Forest + PCA (82.13 %)
6. Random Forest + UMAP (81.55 %)




Figure 3 — Comparaison de l'accuracy des modèles hybrides DL + ML.

Les méthodes de boosting dominent clairement les approches basées sur Random Forest.

4.6 Interprétabilité des Modèles avec SHAP

L'une des limites fréquemment évoquées concernant les modèles d'apprentissage automatique avancés est leur manque d'interprétabilité. Bien que des algorithmes tels que XGBoost, LightGBM ou Stacking offrent d'excellentes performances prédictives, il est souvent difficile de comprendre précisément quelles caractéristiques influencent les décisions du modèle.

Afin d'améliorer la transparence du système proposé, la méthode SHAP (SHapley Additive exPlanations) a été utilisée.

SHAP est basée sur la théorie des jeux coopératifs et permet de mesurer la contribution de chaque caractéristique à la prédiction finale. Chaque variable reçoit une valeur SHAP représentant son importance dans la décision du modèle.

L'utilisation de SHAP présente plusieurs avantages :

- interprétation locale des prédictions individuelles ;
- interprétation globale du comportement du modèle ;
- identification des caractéristiques les plus influentes ;
- amélioration de la confiance dans les résultats obtenus.

Dans le cadre de ce projet, SHAP a été appliqué au modèle présentant les meilleures performances afin d'analyser l'importance relative des caractéristiques extraites par ResNet18.

Analyse des Contributions des Features

Les résultats de SHAP permettent de visualiser l'impact de chaque feature sur les prédictions du modèle. Les caractéristiques ayant les valeurs SHAP les plus élevées sont considérées comme les plus importantes pour la classification.

La figure suivante présente la distribution des valeurs SHAP pour l'ensemble des observations étudiées.




Figure 4 — Importance globale des caractéristiques selon SHAP (interaction values).

L'analyse de cette figure montre que certaines caractéristiques extraites automatiquement par ResNet18 contribuent davantage à la séparation des différentes classes du dataset CIFAR-10.

Ces résultats confirment que les deep features générées par le réseau de neurones contiennent une information discriminante pertinente pour les algorithmes de Machine Learning utilisés dans cette étude.

Discussion des Résultats SHAP

L'approche SHAP apporte une meilleure compréhension du fonctionnement interne du pipeline hybride proposé.

Elle permet notamment :

- d'identifier les caractéristiques les plus influentes ;
- de vérifier la cohérence des décisions du modèle ;
- de détecter d'éventuels biais ou comportements inattendus ;
- d'améliorer l'interprétabilité globale du système.

L'intégration de SHAP constitue ainsi une étape importante vers des modèles de classification plus transparents et plus facilement explicables.

5. Discussion

Les résultats obtenus démontrent l'efficacité de l'approche hybride proposée.

L'utilisation de ResNet18 permet d'extraire des représentations riches sans nécessiter l'entraînement complet d'un réseau profond.

Ces caractéristiques sont ensuite exploitées efficacement par les modèles de Machine Learning.

L'écart de performance observé entre Random Forest et les méthodes de boosting confirme les conclusions de nombreux travaux récents.

Les modèles XGBoost et LightGBM parviennent à exploiter plus efficacement les relations complexes présentes dans les deep features.

L'étude met également en évidence l'intérêt de PCA.

Bien que l'accuracy obtenue avec Random Forest + PCA soit légèrement inférieure à celle du Random Forest classique, la réduction de dimension permet de simplifier considérablement l'espace de représentation tout en conservant l'essentiel de l'information.

Concernant UMAP, les résultats montrent une légère diminution de performance.

Cette observation peut s'expliquer par la perte de certaines informations utiles à la classification lors de la projection non linéaire.

Le meilleur compromis est obtenu par LightGBM + PCA qui combine :

- haute précision ;
- temps d'exécution réduit ;
- faible complexité.

6. Limites de l'Étude

Malgré les résultats encourageants obtenus, certaines limites doivent être soulignées.

Premièrement, une seule architecture de Deep Learning a été étudiée.

L'utilisation de modèles plus récents tels que :

- ResNet50 ;
- EfficientNet ;
- Vision Transformer (ViT)

pourrait conduire à de meilleures performances.

Deuxièmement, les expériences ont été réalisées dans l'environnement Google Colab qui impose certaines contraintes matérielles.

Troisièmement, l'optimisation des hyperparamètres n'a pas été poussée à son maximum afin de limiter les temps d'exécution.

Enfin, l'étude a été menée uniquement sur CIFAR-10.

Une validation sur d'autres datasets permettrait d'évaluer plus précisément la robustesse de l'approche proposée.

7. Conclusion

Ce projet avait pour objectif de concevoir un pipeline hybride combinant Deep Learning et Machine Learning pour la classification d'images.

Les résultats obtenus démontrent la pertinence de cette approche.

L'utilisation de ResNet18 comme extracteur de caractéristiques permet de bénéficier de représentations profondes de qualité tout en réduisant considérablement le coût d'apprentissage.

Les méthodes de boosting se sont révélées particulièrement performantes.

Le meilleur résultat a été obtenu par LightGBM associé à PCA avec une accuracy de 85.92 %.

Les principales contributions de ce travail sont :

- extraction automatique de deep features par ResNet18 ;
- comparaison de plusieurs techniques de réduction de dimension ;
- évaluation de plusieurs modèles de Machine Learning ;
- analyse comparative des performances obtenues.

Ces résultats confirment l'intérêt des approches hybrides pour les tâches de classification d'images.

Dans des travaux futurs, il serait intéressant d'explorer :

- des architectures plus profondes ;
- l'optimisation automatique des hyperparamètres ;
- des techniques d'interprétabilité comme SHAP ;
- d'autres datasets de vision par ordinateur.

Bibliographie

- [1] Krizhevsky, A. Learning Multiple Layers of Features from Tiny Images. University of Toronto, 2009.
- [2] He, K., Zhang, X., Ren, S., Sun, J. Deep Residual Learning for Image Recognition. CVPR, 2016.
- [3] Goodfellow, I., Bengio, Y., Courville, A. Deep Learning. MIT Press, 2016.
- [4] Breiman, L. Random Forests. Machine Learning Journal, 2001.
- [5] Chen, T., Guestrin, C. XGBoost: A Scalable Tree Boosting System. KDD, 2016.
- [6] Ke, G. et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. NeurIPS, 2017.
- [7] McInnes, L., Healy, J. UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction, 2018.
- [8] Jolliffe, I. Principal Component Analysis. Springer, 2002.
- [9] Deng, J. et al. ImageNet: A Large-Scale Hierarchical Image Database. CVPR, 2009.
- [10] Pedregosa, F. et al. Scikit-Learn: Machine Learning in Python. Journal of Machine Learning Research, 2011.